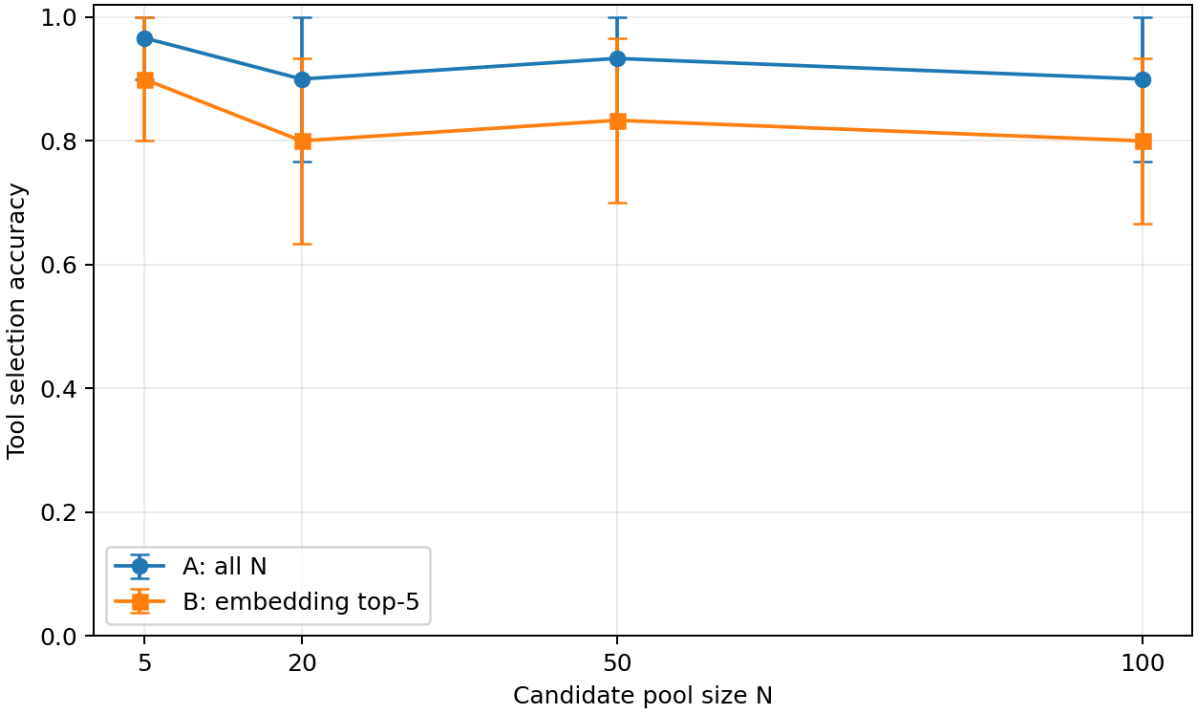
Выбор инструментов и петли агента

Отчет по домашнему заданию 2 | 2026-10-12

Протокол

Пул содержит 100 описаний: 4 инструмента расписания, 24 близких синтетических отвлекающих и 72 из других доменов. Для 30 вручную составленных запросов сравнивались A (все N описаний) и B (top-5 по cosine similarity локальных эмбеддингов) при N = 5, 20, 50, 100, по 3 повтора. Эмбеддинг: sentence-transformers/all-MiniLM-L6-v2; запросы и описания на английском. Генератор: локальная Qwen3-4B (D:\qwen-spec\models\Qwen3-4B); temperature=0.25, top_p=0.85. Запуск локальный, расходы на API — 0; RTX 4050 Laptop, 6 ГБ VRAM, часть весов выполнялась на CPU.

Точность выбора



Усы показывают 95%-й percentile bootstrap-интервал по 10 000 ресэмплов запросов; все три повтора одного запроса остаются вместе. Незавершенные и неуспешные вызовы считаются ошибками в полном знаменателе.

Точность и входные токены

N	Вариант	Точность [95% ДИ]	Recall@5	Входные токены	Успешно / 90
5	A: все N	0.967 [0.900; 1.000]	1.000	271.4	90/90
5	B: top-5	0.900 [0.800; 1.000]	1.000	271.4	90/90
20	A: все N	0.900 [0.767; 1.000]	0.867	678.6	90/90
20	B: top-5	0.800 [0.633; 0.933]	0.867	248.7	90/90
50	A: все N	0.933 [0.833; 1.000]	0.867	1498.5	90/90
50	B: top-5	0.833 [0.700; 0.967]	0.867	228.3	90/90
100	A: все N	0.900 [0.767; 1.000]	0.800	2847.1	90/90
100	B: top-5	0.800 [0.667; 0.933]	0.800	209.9	90/90

Количество входных и выходных токенов измеряется локальным токенизатором Qwen3; ошибки генерации остаются в знаменателе. Coverage сохранен в CSV/JSON summary.

Петли, результаты и ограничения

20 задач x 3 повтора; знаменатель каждого условия - 60 эпизодов.

Условие	Петли	Средние шаги	Средние токены	Успех	Сбой модели
Пусто, без guard	7/60 (0.117)	1.85	603.3	59/60 (0.983)	0
Пусто + LoopGuard	7/60 (0.117)	1.78	543.1	53/60 (0.883)	0
Пусто с подсказкой	1/60 (0.017)	1.87	629.7	60/60 (1.000)	0

Пустые ответы генерировались с вероятностью 0.5. LoopGuard применял окно из 6 последних вызовов и останавливал последовательность после трех одинаковых вызовов подряд или паттерна A-B-A-B. В условии с подсказкой пустой результат сопровождался текстом «ничего не найдено; попробуйте другое значение date».

Вывод

Подсказка в ответе инструмента дала меньше циклов: 1/60 (1,7%) против 7/60 (11,7%) с LoopGuard; успех составил 60/60 против 53/60. В этом прогоне исправление ответа инструмента помогло сильнее guard в harness. Это наблюдение относится только к данному малому синтетическому прогону.

Угрозы валидности

- Небольшая ручная выборка из 30 запросов и повторение трех типов расписания ограничивают обобщение; повторы внутри запроса зависимы.

- Отвлекающие описания, расписание из трех синтетических записей и упрощенный harness могут отличаться от реального MCP-каталога и поведения агента.

- Результаты зависят от версии Qwen3-4B, настроек генерации и случайности; они не переносятся автоматически на другие модели и инструменты.

Сырые логи выбора: 720 записей. Полный JSONL каждого условия, сводки CSV/JSON и скрипты приложены в репозитории.